

**České vysoké učení technické v Praze
Fakulta elektrotechnická
Katedra telekomunikační techniky**

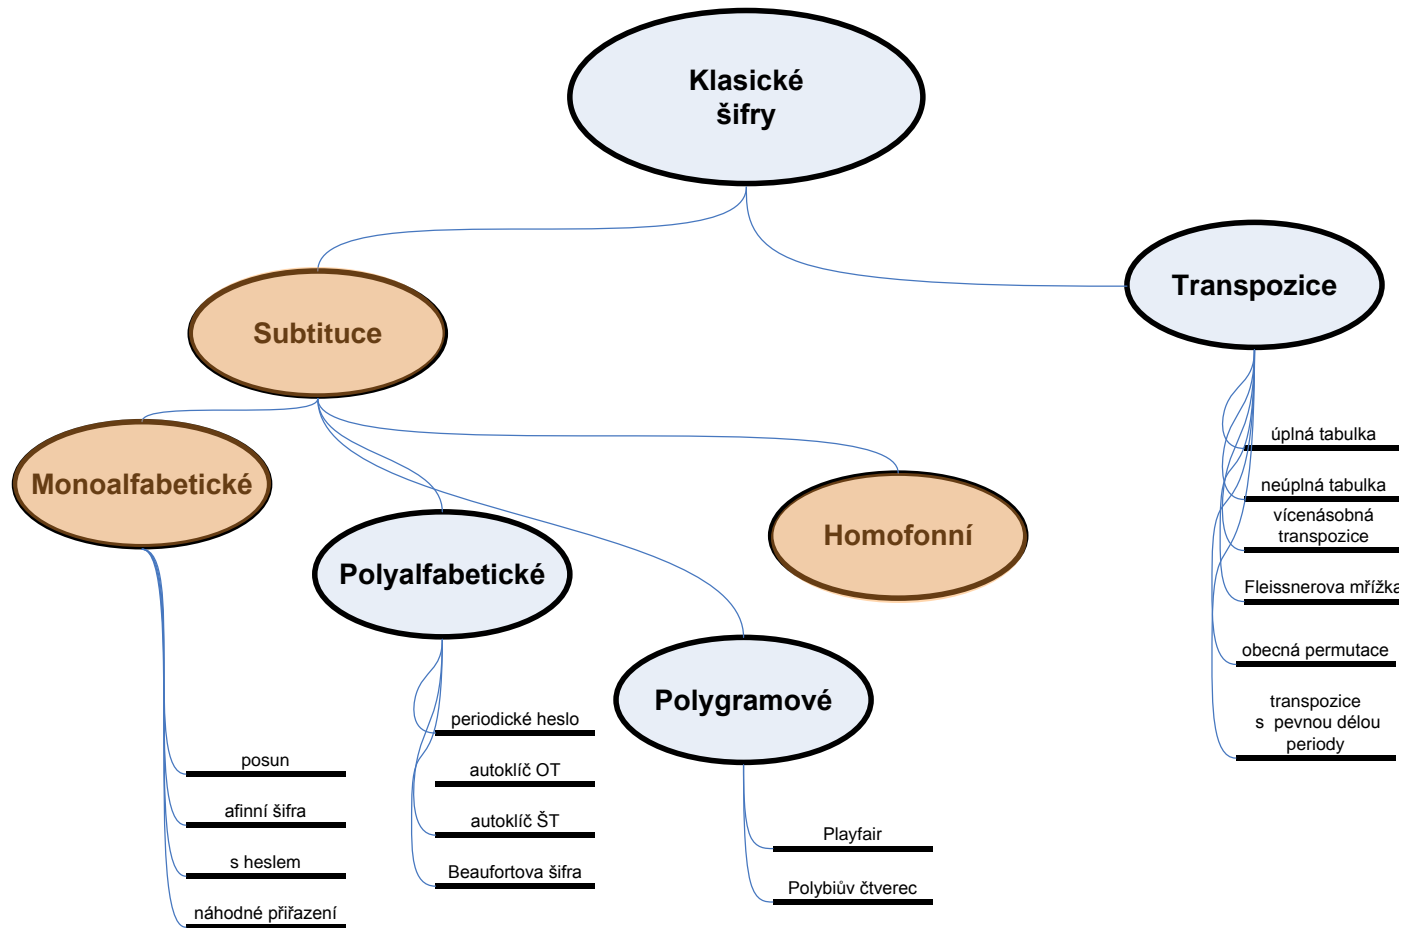
2.cvičení – Monoalfabetické substituční šifry, frekvenční analýza, index koincidence

Ing. Tomáš Vaněk, Ph.D. tomas.vanek@fel.cvut.cz





Rozdělení klasických šifer





Rozdělení klasických substitučních šifer

- Jednoduchá substituční šifra (monoalfabetická substituce, jednoduchá záměna) je šifra, ve které se každý znak otevřeného textu nahradí příslušným znakem šifrovaného textu.
 - Existuje **unikátní mapování** znaků abecedy OT na znaky abecedu ŠT → **mono**alfabetická
 - Homofonní substituční šifra se podobá jednoduché substituční šifře, avšak jeden znak otevřeného textu může být nahrazen jedním z několika možných znaků šifrovaného textu. Znak „A“ by mohl být nahrazen např. 5, 10, 13 nebo 25, „B“ např. 6 nebo 15 atd. Počet znaků zašifrovaného textu pro jeden znak otevřeného textu se může lišit.
 - Polygramová substituční šifra je ta, ve které šifrování probíhá mezi skupinami znaků. Skupina „AA“ může být nahrazená skupinou „JH“, „AB“ skupinou „DK“ atd.
 - Polyalfabetická substituční šifra se skládá z několika jednoduchých šifer, které se postupně pro jednotlivé znaky otevřeného textu střídají.
-



Mapování anglické abecedy

- pro potřeby šifrovacích transformací je nejprve nutné převést abecedu na čísla
- používá se tento předpis

A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S	T	U	V	W	X	Y	Z
0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20	21	22	23	24	25



Monoalfabetická substituce – jednoduchý posun

Šifrování:

$$C_i = P_i + A \bmod 26 \quad A \in \langle 0; 25 \rangle$$

Dešifrování:

$$P_i = C_i - A \bmod 26$$

- Césarova šifra $A=3$
- celkem existuje 26 variant jednoduchého posunu (25 použitelných)
- luštění bez znalosti klíče
 - brute force (pouze 25 kombinací)
 - frekvenční analýza



Monoalfabetická substituce – afinní šifra

Šifrování:

$$C_i = A \cdot P_i + B \bmod 26 \quad B \in \langle 0; 25 \rangle, \quad A \in \langle 1; 25 \rangle \quad \gcd(A, 26) = 1$$

Dešifrování:

$$P_i = A^{-1}(C_i - B) \bmod 26; \quad A^{-1} \text{ je multiplikativní inverze } A \bmod 26$$

- existuje $\varphi(26) \cdot 26 = 312$ kombinací
 φ - Eulerova funkce φ
- jednoduchý posun je speciální případ afinní šifry
- luštění bez znalosti klíče
 - brute force
 - frekvenční analýza + zpětný výpočet koeficientů A,B




Monoalfabetická substituce s klíčem

Abeceda OT: A B C D E F G H I J K L M N O P Q R S T U V W X Y Z

Abeceda ŠT: H E S L O A B C D F G I J K M N P Q R T U V W X Y Z

- pokud se v klíči opakují některá písmena, pak se zaznamená pouze první výskyt: LOKOMOTIVA -> LOKMTIVA
- nejprve se opíše klíč a poté zbývající znaky abecedy (s vynechanými písmeny, která jsou součástí klíče)
- při špatně zvoleném klíči pomůže FA
 - od posledního znaku klíče v abecedě se abeceda OT mapuje 1:1 na abecedu ŠT (viz příklad nahoře, kde od znaku s se znaky mapují sami na sebe)
- luštění bez znalosti klíče možné s využitím frekvenční analýzy



Monoalfabetická subst. – náhodná transformace

- náhodné přiřazení znaků abecedy OT a ŠT
- počet možných kombinací $26! \approx 4 \times 10^{26}$

Příklad:

Abeceda OT: A B C D E F G H I J K L M N O P Q R S T U V W X Y Z

Abeceda ŠT: G = ' E * ~ 2 U D F : I > C - 5 R 7 V S 3 { H X / M



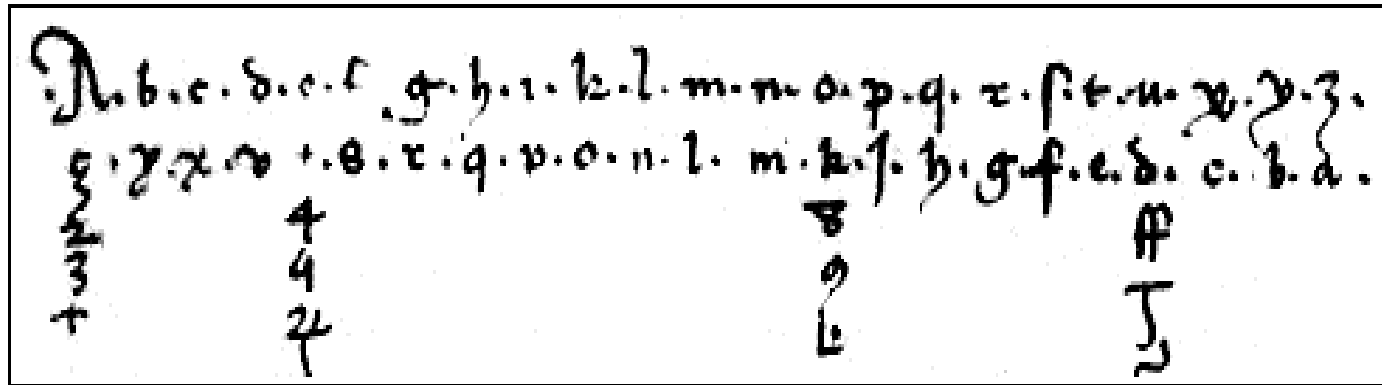
Homofonní šifra

- cca polovina 14. století
- snahy o zdokonalení monoalfabetické substituce
- jeden znak OT je zašifrován na různé znaky ŠT
- počet možných znaků závisí na četnosti výskytu daného znaku
- její použití lze jednoduše rozpoznat - počet různých znaků v ŠT je výrazně větší než počet znaků v dané národní abecedě
- homofonní šifra nepřinesla výrazné vylepšení bezpečnosti
- různé reprezentace jednoho znaku lze odhalit pomocí vyhledání „skoro shodných“ slov
 - stejná slova OT zašifrovaná do ŠT lišící se jen velmi málo např.

50	12	9	87	81	32	21
50	12	9	6	81	32	21

Homofonní šifra – historické příklady

- Simeon de Crema z Mantovy (1401)



Nomenklátor

- kombinace homofonní monoalfabetické substituce a
 - částečné kódové knihy pro slabiky / jména
 - klamačů
 - symbolů pro zdvojení znaku
- od 14. století
- používán přes 500 let, protože byl
 - jednoduchý
 - rychlý
- kódová kniha měla i stovky až tisíce slov

více reprezentací
jednoho znaku

Letter, Cifrate									
a	b	c	d	e	f	g	h	i	j
v	n	I	X	U	q	6	p	z	λ
đ				č					
k	l	m	n	o	p	q	r	s	t
2	L	7	o	W	H	#	e	X	
				q					
t	u	x	y	z	æ	g	u		
b	+	č	ž	2r	g	ψ	X		
h					↑				

Null.

± X Θ X 7 9 Z E 6 M A

HVΘ1d7b69048Y eXI7U xIMe1eNUxM55

klamače



Homofonní šifra

- I u homofonních šifer lze v ŠT objevit vzory charakteristické pro dvojice/trojice znaků (frekvence digramů/trigramů)

Řešení: 1) polygramové substituce

- šifrují najednou více znaků OT
- Playfair, Hillova šifra

2) polyalfabetické šifry

- používají více abeced
- Vigenére, Beaufort

- více na příštím cvičení


Nástroje pro luštění monoalfabetických substitucí

- Frekvenční analýza
 - 9. st. n.l.
 - أبو يوسف يعقوب ابن إسحاق الكندي
(Abū Yūsuf Ya'qūb ibn Ishāq al-Šabbāḥ al-Kindī)
 - A Manuscript On Deciphering Cryptographic Messages
- Index coincidence
 - 1922
 - William Frederick Friedman
 - The Index of Coincidence And Its Applications in Cryptanalysis

هذا هو الكتاب الذي كتبه أبو يوسف يعقوب ابن إسحاق الكندي في سنة 800 م. وهو من أشهر كتب في علم التشفير. وفيه يشرح كيف يمكن فك الشفرات التي كانت تستخدم في ذلك الوقت. وهو يعتبر من أهم الكتب في هذا المجال.

والله اعلم بالصواب

هذا هو الكتاب الذي كتبه أبو يوسف يعقوب ابن إسحاق الكندي في سنة 800 م. وهو من أشهر كتب في علم التشفير. وفيه يشرح كيف يمكن فك الشفرات التي كانت تستخدم في ذلك الوقت. وهو يعتبر من أهم الكتب في هذا المجال.





Index coincidence

- IC je míra relativní četnosti znaků v šifrovaném textu, neboli odhad pravděpodobnosti, že při náhodném výběru dvou znaků ŠT oba znaky reprezentují stejný znak OT
- Pro abecedu o c prvcích platí, že

$$IC = \frac{\sum_{i=1}^c n_i(n_i - 1)}{N(N - 1)}$$

N délka textu

n_i četnost výskytu znaku i v textu délky N

c počet znaků abecedy



Index coincidence

- Pro anglickou abecedu (26 znaků) platí,

$$IC = \frac{26 \sum_{i=1}^{26} n_i (n_i - 1)}{N(N-1)} \approx \frac{26 \sum_{i=1}^{26} n_i^2}{N^2} = \sum_{i=1}^{26} p_i^2 \cong 0,067$$

N délka textu

n_i četnost výskytu znaku i v textu délky N


p_i relativní četnost výskytu znaku i v anglické abecedě

- vztah platí pro $N \gg n$
- IC má tuto hodnotu pro OT, ale také ŠT, který vznikl s využitím monoalfabetické substituce a/nebo transpozice
- přesná hodnota IC je mimo způsobu zašifrování ovlivněna také délkou a charakterem analyzovaného textu



Frekvenční analýza

- nástroj pro luštění monoalfabetických substitucí



Rozložení četností výskytu jednotlivých znaků v běžné angličtině

Další frekvenční statistiky jazyka

- kromě analýzy jednotlivých znaků, lze analyzovat i četnost výskytu dvojic (**digramy**) nebo trojic (**trigramy**) resp. obecně n-tic (**n-gramy**)
- nejčastější digramy v AJ
 - TH, HE, IN, ER, AN, RE, ED, ON, ES, ST, EN, AT, TO, NT, HA, ND, OU, EA, NG, AS, OR, TI, IS, ET, IT, AR, TE, SE, HI, OF
- nejčastější trigramy v AJ
 - THE, ING, AND, HER, ERE, ENT, THA, NTH, WAS, ETH, FOR, DTH



Kryptoanalýza monoalfabetických substitučních šifer

Krok č.1 - určit jak byl text zašifrován

- 1) Pokud $IC \sim 0,067$ **může** se jednat o monoalfabetickou substituci
- 2) Frekvenční analýza - pokud jsou v grafickém vyjádření vidět výrazné rozdíly mezi četnostmi výskytu jednotlivých znaků (hodnoty na 10% i pod 2%) a současně rozložení četností neodpovídá otevřenému textu, jedná se o monoalfabetickou substituci

Krok č.2 - dešifrování šifrového textu

- 1) Prostý posun – pouze 26 kombinací, stačí posunovat ŠT a sledovat odchylky od FA otevřeného anglického textu



Kryptoanalýza monoalfabetických substitučních šifer

2) Afinní šifra - 2 možnosti

a) hrubou silou

existuje pouze 312 možných kombinací → vygenerovat je
→ nalézt správné řešení (ručně nebo s využitím slovníku)

b) chytrou hlavou – výpočet konstant A,B

1. Z výsledků FA odhadnout, jak se transformovaly dva konkrétní znaky OT (např. $E \rightarrow J$ a $A \rightarrow X$).
2. Sestrojit dvě rovnice $C_i = A \cdot P_i + B \pmod{26}$ o dvou neznámých (A,B), kde za C_i, P_i se dosadí číselné hodnoty odpovídající hodnotám odhadnutých znaků.
3. Rovnice vyřešit. Pokud rovnice nemají řešení, je nutné se vrátit zpět ke kroku 1 a zvolit jinou transformaci znaků OT na ŠT



Kryptoanalýza monoalfabetických substitučních šifer

3) Monoalfabetická šifra s klíčem

a) napsat nebo si najít program, který text rozluští

- Kvalitní program tento typ šifry na běžném počítači rozluští v řádu jednotek sekund.

b) ručně s využitím FA

- odhad několika znaků s velkými četnostmi výskytu – E,T,A případně ještě I,O,N nebo S
- částečná rekonstrukce textu
- hledání struktur jako je T_E , T_E_E ...nalezení H
- postupné odhalování dalších znaků OT

Dotazy

